

# Introdução ao Python

## 3. NumPy

Rodrigo Barbosa de Santis

# Sumário

- Introdução – Python puro vs NumPy
- Inicialização de Vetores
- Gradiente descendente

# Python puro vs NumPy

# Python puro

```
>> import time
>> l = 10000000
>> start = time.time()
>>
>> a, b = range(l), range(l)
>> c = []
>> for i in a:
>> c.append(a[i] * b[i])
>>
>> t = time.time() - start
>> print( " Tempo: %s" % t)
Tempo: 4.49s
```

# NumPy

```
>> import time
>> import numpy as np
>> l = 10000000
>> start = time.time()
>>
>> a = np.arange(l)
>> b = np.arange(l)
>> c = a * b
>>
>> t = time.time() - start
>> print( " Tempo: %s" % t)
Tempo: 0.37 s
```

# Inicialização de vetores

<code>zeros((M,N))</code> <code>ones((M,N))</code> <code>empty((M,N))</code>	vetor com zeros, M linhas, N colunas vetor com uns, M linhas, N colunas vetor vazio, M linhas, N colunas
<code>zeros_like(A)</code> <code>ones_like(A)</code> <code>empty_like(A)</code>	vetor com zeros, mesmo formato de A vetor com uns, mesmo formato de A vetor vazio, mesmo formato de A
<code>random.random((M,N))</code> <code>identity(N)</code> <code>array([[1.5,2,3],[4,5,6]])</code>	vetor com números aleatórios, MxN matriz identidade NxN, ponto flutuante cria a partir de lista ou tupla
<code>arange(l,F,P)</code> <code>linspace(l,F,N)</code>	vetor com o início l, fim F, passo P vetor com N números no espaço de l até F

# Gradiente descendente

$$\Theta^1 = \Theta^0 - \alpha \nabla J(\Theta) \text{ evaluated at } \Theta^0$$

Diagram illustrating the gradient descent update formula with annotations:

- $\Theta^1$ : next position
- $\Theta^0$ : current position
- $\alpha$ : small step
- $\nabla J(\Theta)$ : direction of fastest increase
- $-\alpha \nabla J(\Theta)$ : opposite direction

